

大语言模型及应用

Instructor: Xiaohan Ma(马晓寒), Ph.D.

Graduate School of Information and Communication Technology,

Ajou University, Korea

maxiaohan@ajou.ac.kr

提示生成与零样本推理


课程大纲

1. 什么是提示？我们如何对语言模型进行提示？
2. 提示词工程
 - 手动提示
 - 自动化提示
 - 离散提示与连续提示
1. 上下文学习
2. 思维链提示及其他提示变体

语言建模简史

- 直到**10-15年前**：语言模型利用文本语料库中的词频数据库来估算概率
 - 处理其他任务的自然语言处理（NLP）系统通常忽略语言模型，且需要**数百万个示例**才能完成任务学习
- **10年前**：深度学习与迁移学习的结合使语言模型变得高效
 - 自然语言处理（NLP）系统开始将语言模型作为学习任务的起点，但仍需**数千个**示例才能完成这一过程
- **过去3年**：规模化（数据与模型）
 - GPT系列模型
 - 只需提示或指示这些模型完成任务

有监督微调



通常需要数万^个样本！！！！

参数高效微调

只需针对每个任务对参数子集进行微调




Image: [\(He et al. 2022\)](#)

仍然需要数千个示例!!!

为什么不总是需要微调


- 模型再海量数据上预训练，获得了广泛的知识 and 推理能力
- 只要通过合适的提示Prompt，就能激发模型完成很多任务

对比项	Prompt (提示)	微调 (SFT)
是否改模型	✗ 不改模型	✓ 改变模型参数
是否需要数据	✗ 不需要数据	✓ 需要监督数据
成本	😊 低 (几乎无训练成本)	😞 高 (训练成本高)
适用场景	通用任务、开放领域、快速验证想法	专业任务、特定领域、需要稳定输出格式
优点	快速、灵活、无额外参数	效果更稳定、可控性更强
缺点	受模型能力上限限制，效果可能不稳定	需要数据、训练成本高、迭代慢



核心思想：我们手动设计一个“提示词”，用以演示如何将任务表述为生成任务。

完全无需更新模型权重！



过程：

1 提供示例

给模型几个输入输出示例，描述任务是什么。

2 推断任务模式

模型在上下文中推断出任务的模式（这里是翻译）。

3 完成新输入

模型对新的输入进行同样的处理，生成结果。




模型不是记忆某个答案，而是推断出“规则”并应用。

将目标任务重新表述为语言建模任务

核心思想:把原本的分类任务(正/负)改造成“预测下一个词”的语言建模任务,这样才能充分利用大语言模型的能力,并支持监督微调。


❌ 传统方法 (基于分类头 Head-based fine-tuning)



- 使用 [CLS] 表示整句作为输入。
- 模型通过分类头 (CLS head) 直接预测类别。
- 这种方式 **没有利用语言模型的“下一个词预测”能力**, 不符合大模型的预训练范式, 效果较差。



✅ 改进方法 (基于提示的微调 / Prompt-based fine-tuning)



- 在原句后添加模板: It was [MASK] .
- [MASK] 位置由模型预测下一个词。
- 将预测词映射到目标标签:
great → positive, terrible → negative.
- 充分利用语言模型的能力, 更适合监督微调。



Prompt-based Fine-tuning 理论基础

1. 任务形式化：改写为 (Masked) LM 问题

原始任务
(分类任务)

例：这句话是正面
还是负面？

正面 负面

改写后 (使用模板 Template)

[CLS] No reason to watch . It was [MASK] . [SEP]

Input (原始文本)

Template (模板)

★ 把“选择标签”变成“预测一个词”

2. 标签词映射 (Label Word Mapping)

选择标签到词的映射 $\mathcal{M}(y)$

任务标签 y	映射词 $\mathcal{M}(y)$
positive	→ great
negative	→ terrible
...	...

词表中的
具体词



通常选择语义明确、互斥性强的词作为标签词

Prompt-based Fine-tuning理论基础

3. 用语言模型预测标签词

模型在 [MASK] 位置预测下一个词

预训练语言模型 (如 LLaMA, GPT 等)

[CLS] No reason to watch . It was [MASK] . [SEP]

预测位置

模型输出：在词表上对所有词的概率分布，找到最可能的标签词

Prompt-based Fine-tuning理论基础

3. 用语言模型预测标签词

模型在 [MASK] 位置预测下一个词

预训练语言模型 (如 LLaMA, GPT 等)

[CLS] No reason to watch . It was [MASK] . [SEP]

预测位置

模型输出：在词表上对所有词的概率分布，找到最可能的标签词

Prompt-based Fine-tuning理论基础

4. 概率计算（本质是 LM 的词预测）

给定输入 x_{prompt} ，标签 y 的概率定义为：

$$p(y \mid x_{\text{in}}) = p([\text{MASK}] = \mathcal{M}(y) \mid x_{\text{prompt}})$$

$$= \frac{\exp(w_{\mathcal{M}(y)} \cdot \mathbf{h}_{[\text{MASK}]})}{\sum_{y' \in \mathcal{V}} \exp(w_{\mathcal{M}(y')} \cdot \mathbf{h}_{[\text{MASK}]})},$$


$\mathbf{h}_{[\text{MASK}]}$ ：模型在 [MASK] 位置的隐藏状态向量

$w_{\mathcal{M}(y)}$ ：标签词 $\mathcal{M}(y)$ 对应的输出层权重向量


$\mathcal{V}$ ：词表（所有词的集合）



$\mathbf{h}_{[\text{MASK}]}$
(隐藏状态)



输出层权重（词表）



词概率分布
(在词表上)

预测标签： $\hat{y} = \operatorname{argmax}_{y \in \mathcal{V}} p(y \mid x_{\text{in}})$

取概率最大的标签作为预测结果

Prompt-based Fine-tuning理论基础

5. 训练目标（可微分，可反向传播）

使用监督数据 (x_{in}, y) 进行训练，优化使正确标签词的概率最大：

$$\mathcal{L} = -\log p([MASK] = \mathcal{M}(y) \mid x_{prompt})$$

- ✓ 本质是语言建模的交叉熵损失
- ✓ 可对模型所有参数进行微调（或只微调部分参数）
- ✓ 与预训练目标一致，训练稳定、收敛快

训练过程



训练数据（带标签）

"No reason to watch." → negative



构造模板 + 映射词

It was [MASK]. negative → terrible



最小化损失，更新模型参数

例子-1

我们已经使用如下 Prompt 模板，并让模型输出 [MASK] 位置的隐藏状态向量：

【Prompt 模板】

[CLS] This movie is boring and too long. Overall, it was [MASK]. [SEP]

【模型输出】

[Mask] 位置的隐藏状态向量 $\mathbf{h}_{\text{MASK}}$ (维度为 4)：

$$\mathbf{h}_{\text{MASK}} = [0.4, -0.1, 0.3, 0.8]$$

【词向量 (输出层权重)】 (维度也为 4)

候选词 (v)	词向量 $\mathbf{w}_v$
great	[0.2, 0.1, 0.3, 0.7]
terrible	[0.5, 0.2, -0.1, 0.4]

【要求】

1. 请计算每个候选词的 logits (点积结果)，写出计算过程。

• $z_{\text{great}} = \mathbf{h}_{\text{MASK}} \cdot \mathbf{w}_{\text{great}} =$ _____

计算过程：_____

• $z_{\text{terrible}} = \mathbf{h}_{\text{MASK}} \cdot \mathbf{w}_{\text{terrible}} =$ _____

计算过程：_____


2. 请将 logits 通过 softmax 转换为概率。

• $p(\text{great}) =$ _____ • $p(\text{terrible}) =$ _____

3. 根据概率，模型最终预测的标签是什么？ (positive / negative)

答：_____

推理流程



例子-2

我们有一个情感分类任务（正面 / 负面），使用 prompt-based 方法。

- 标签词映射 (Label Mapping $\mathcal{M}$) :

positive → great

negative → terrible

给定两个不同的 prompt:

Prompt A: No reason to watch. It was [MASK].

Prompt B: No reason to watch. Overall, the movie was [MASK].

模型在 [MASK] 位置的输出 logits (仅给出与标签词相关的两个词) :

Prompt	logit(great)	logit(terrible)
A	2.0	2.5
B	1.5	3.0

问题:

- 1 计算两个 prompt 下，模型预测为 positive (great) 和 negative (terrible) 的概率。
- 2 两个 prompt 的预测结果分别是什么？
- 3 为什么换一个 prompt，模型的预测结果会改变？

What makes a good prompt? for an NLP task,



*GPT3: “a good prompt is one that is specific and **provides enough context for the model** to be able to generate a response that is relevant to the task.”*

提示词工程的奥秘

1 BoolQ (问答任务)

目标: 给定一段文字 p 和一个问题 q , 回答 Yes / No



文本 p

+



问题 q



p . Question: q ? Answer: <MASK>.

× 效果差

准确率
低

× 效果一般

p . Based on the previous
passage, q ? <MASK>.

准确率
中

✓ 效果好

Based on the following passage,
 q ? <MASK>. p

准确率
高



更自然、更清晰的表达方式, 模型更容易理解

2 WiC (词义判断任务)

目标: 给定两个句子 s_1 和 s_2 , 判断词 w 在两句中是否同义

句子 s_1

句子 s_2

+

词 w



" s_1 " / " s_2 ".

Similar sense of " w "?

<MASK>.

× 效果差

准确率
低

✓ 效果好

s_1 s_2

Does w have the same
meaning in both sentences?
<MASK>.

准确率
高



更像人类提问的方式, 模型效果更好

提示词工程的“黑魔法”

任务是找到一个**模板 T**和**一组标签词 M(y)**，二者结合使用时效果良好



1. 需要领域经验

需要了解模型的偏好和训练数据的分布



2. 需要反复试验

不同写法都要尝试，没有固定公式



3. 微小变化，结果差很多

一个词、一个顺序、一个标点，效果可能天差地别



我们的任务：找到一个好的**模板 T**和**标签词 M(y)**

模板 T (怎么问)

即 prompt 的句式结构和表达方式



好的模板 T

- 清晰
- 自然
- 符合人类习惯
- 模型更容易理解



差的模板 T

- 表达生硬
- 含糊不清
- 歧义大
- 模型难以理解

+

标签词 M(y) (用什么词回答)

即模型输出的词或短语

不同标签词，效果可能不同

Yes / No

True / False

Correct / Incorrect

Same / Different

Positive / Negative


...



选择模型更“偏好”的词，效果更好


输入

(文本 + 问题)



设计好的 Prompt

= 模板 T + 标签词 M(y)



模型理解并生成答案



更好的效果

(更高准确率)



EmotionPrompt

Original Prompt

Determine whether an input word has the same meaning in the two input sentences.

EmotionPrompt (Ours)

Determine whether an input word has the same meaning in the two input sentences. **This is very important to my career.**

LLMs

ChatGPT

T5-Large

Vicuna

Bloom

GPT4

Llama 2

Original

Ours

0.51

0.63

0.03

0.11

0.46

0.57

0.52

0.57

0.67

0.71

0.40

0.60



Psychology

<https://arxiv.org/abs/2307.11760>

<https://arxiv.org/abs/2205.11916>

6	Add “I’m going to tip \$xxx for a better solution!”	https://arxiv.org/abs/2312.1617
7	Implement example-driven prompting (Use few-shot prompting).	1
8	When formatting your prompt, start with ‘####Instruction####’, followed by either ‘####Example####’ or ‘####Question####’ if relevant. Subsequently, present your content. Use one or more line breaks to separate instructions, examples, questions, context, and input data.	
9	Incorporate the following phrases: “Your task is” and “You MUST”.	
10	Incorporate the following phrases: “You will be penalized”.	


- 任务：生成“正好 200 个字符”的故事使用 API 批量生成（100 次/条件）评价指标：字符长度分布均方误差（MSE）KS 检验 p 值
 - You are a world-famous writer. Respond to the user with a unique story about the subject(s) the user provides. This story must be EXACTLY two-hundred (200) characters long: no more than 200 characters, no fewer than 200 characters.

惩罚

- 如果你未能提供符合所有约束条件的回复，你将被罚款500美元/1000美元/10万美元。

Distribution of Character Lengths of ChatGPT Output by Tip Incentive

100 generations each, targeting 200 characters. gpt-3.5-turbo-0125, temperature = 1




Max Woolf – minimaxir.com

- 测试了另外六种不同的小费激励措施以求全面：
 - 如果你的回答符合所有限制，你将获得泰勒·斯威夫特演唱会的前排门票。
 - 如果你能提供符合所有约束的回应，你将实现世界和平。
 - 如果你能给出符合所有条件的回复，你会让妈非常骄傲。
 - 如果你能给出符合所有限制的回复，你将遇见真爱并幸福地生活下去。
 - 如果你能给出符合所有限制的回答，你将保证进入天堂。
 - 如果你的回答符合所有限制，你将获得终身巧克力供应。

Distribution of Character Lengths of ChatGPT Output by Tip Incentive

100 generations each, targeting 200 characters. gpt-3.5-turbo-0125, temperature = 1

- ChatGPT 最在意世界和平
- ChatGPT真的不关心它的母亲。




神奇咒语？

- 神奇咒語越來越不神奇

解数学
应用题

GPT 3.5	2023 年 6月 的版本	2024 年 2 月 的版本
沒有神奇咒语	72%	85%
“Let’s think step by step”	88%	89%

人工Prompt的问题



人工 Prompt 的主要问题



成本高

反复测试、修改，
耗时耗力



不稳定


微小改动可能导致
效果大幅变化




依赖经验

需要领域知识和
大量经验积累


Prompt 自动化



从语料中挖掘Prompt模板



例子 从语料中挖掘“首都”关系模板



改写Prompt

原始 Prompt (种子)

任务：判断两个句子中
词 w 是否具有相同含义。

原始 Prompt:

s1 s2
Does w have the same
meaning in both
sentences?

示例输入:

s1: The bank was closed.
s2: He sat on the river bank.
w: bank

改写方法 (生成候选 Prompt)

1. 1. 回译 (Back Translation)



英文
Prompt

翻译
成中文

再翻译
回英文

候选 Prompt 示例

Do s1 and s2 use w with
the same meaning?
Is the meaning of w
identical in both
sentences?
.....

2. 同义词替换 (Synonym Replacement)



替换关键词 / 短语

same	→	identical
meaning	→	sense
both	→	each

候选 Prompt 示例

Do s1 and s2 use w with
the **identical sense** in
each sentence?
Is w used with the same
sense in both sentences?
.....

3. 句式 / 结构改写 (Paraphrase)



改变句式结构



候选 Prompt 示例

Compare the usage of w
in s1 and s2. Are their
meanings the same?
Please determine whether
the word w has the same
meaning in s1 and s2.
.....

评估与选择



对每个候选 Prompt:

- ✓ 输入同一批数据
- ✓ 模型生成答案
- ✓ 计算性能 (准确率等)

选择效果最好的 Prompt



最佳 Prompt (示例)

Do s1 and s2 use w with
the same meaning?

准确率: 92.1% ✓

自动化优化方法



高级提示


1. 连续提示
2. 结合演示的提示法
3. 常见的提示变体
 - 思维链
 - 由简入繁的提示法
 - 思维计划

连续提示

一些方法探索了连续提示（有时也称为软提示），该方法直接在模型的嵌入空间中对其进行提示。


其中一种方法（我们之前已经提到过）是**前缀调优**。

- 在保持语言模型参数**不变**的情况下，将一组连续的**任务特定向量**附加到输入序列的前面。
- 从数学角度而言，在给定**可训练**的前缀矩阵 M_ϕ 和**固定**的预训练语言模型 θ 的条件下，优化对数似然目标函数。



为什么软提示有效

- 1)软提示在向量空间提供了更直接的引导
 - 文字Prompt 需要经过分词和嵌入，信息可能丢失或被稀释;
 - 软提示直接在嵌入层注入任务信号，更直接地影响模型内部表示
- 2)软提示提供了更强的表达能力
 - 离散的文字Prompt 受限于词表(有限选项);连续向量是高维实数向量，表达空间几乎无限，可以编码更丰富、更细粒度的指令。
- 3)软提示可以被训练，自动适配任务
 - 通过优化目标让模型输出正确答案，软提示向量会自动调整到最有用的位置(告诉模型该关注什么、忽略什么)。



少样本提示：通过示例进行提示

如果我们为任务准备了一小批输入-输出示例。

- 这些示例可以作为我们希望语言模型（LM）模仿的行为的**演示**。

我们可以设计包含这些演示的提示词：

在**标准提示**“法国的首都是 [X]”前添加以下示例：

“英国的首都是伦敦。德国的首都是柏林。法国的首都是 [X]”。

与之前一样，无需对模型进行参数更新！

少样本提示:

这种通过示例进行提示的想法也被称为**上下文学习**

在许多自然语言处理基准测试中，基于大型模型的上下文学习在性能上可**与使用大量标注数据训练的模型相媲美**。

工作原理

1. 任务描述



告诉模型要做什么
(自然语言描述任务)

2. 提供少量示例 (Few-shot)

示例 1 输入: [示例输入1] → 输出: [示例输出1]

示例 2 输入: [示例输入2] → 输出: [示例输出2]

...

示例 N 输入: [示例输入N] → 输出: [示例输出N]

3. 模型学习规律



模型从示例中
推断规则和模式

4. 新输入 (待预测)

输入: [新的输入]

5. 模型生成输出

输出: [预测结果]



核心思想: 用少量示例在上下文中“教会”模型任务 → 模型模仿示例的规律 → 泛化到新的输入

冷知识竞赛



1. 多实体问题

(Avg. entities / question)

特点: 问题中包含多个实体

示例问题:

Which **politician** won the **Nobel Peace Prize** in **2009**?

涉及实体:

politician (政治家)

Nobel Peace Prize (诺贝尔和平奖)

2009 (年份)

答案:

Barack Obama



2. 细粒度答案类型

(Fine-grained answer type)

特点: 需要特定类型的精确答案

示例问题:

What **fragrant essential oil** is obtained from **Damascus Rose**?

答案类型:

fragrant essential oil (芳香精油) — 一种特定类别的物质

答案:

Rose oil



3. 粗粒度答案类型

(Coarse-grained answer type)

特点: 只需较宽泛的类型答案

示例问题:

Who won the **Nobel Peace Prize** in **2009**?

答案类型:

Person (人) — 只需回答“人名”即可

答案:

Barack Obama



4. 时间范围问题

(Time frame)

特点: 问题中包含时间信息

示例问题:

What was photographed for the first time in **October 1959**?

涉及时间:

October 1959 (1959年10月)

答案:

The far side of
the Moon



5. 比较类问题

(Comparisons)

特点: 需要比较或排序

示例问题:

What is the appropriate name of the **largest** type of frog?

比较关系:


需要比较不同类型的青蛙, 找出“最大”的

答案:

Goliath frog

通过示例引导与 规模调整

Few-shot prompting 随着模型变大，会显著提高 TriviaQA 的准确率。



规模对上下文学习的影响。在TriviaQA数据集上，使用不同版本的GPT-3，并在少量样本提示中采用不同数量的示例。
摘自Brown等人（2020）

GPT-3时代：少样本学习中的三大问题

1 示例引导何时有效？原因何在？

✓ 有效的情况

- 有明确模式
- 有固定格式
- 可模仿规则的任务
(如：翻译、分类、代码生成)

✗ 不太稳定的情况

- 开放推理、复杂数学
- 长逻辑链等
- (很难靠少量例子学到完整推理)



原因：GPT-3 更像“高级文本续写器”，不擅长理解意图，需要示例来“教”它任务规则。

2 提示中应包含哪些示例？

差示例（不相关）

Q: 我喜欢这部电影。
A: Positive

Q: 这太糟糕了。
A: Negative

问题：过于简单、与目标输入不相似

好示例（相似）

Q: 剧情慢但很感人。
A: Positive

Q: 画面很美但故事无聊。
A: Negative

特点：与目标输入更相似，效果更好



研究发现：相似、覆盖全面、具有代表性的示例更有效

3 示例顺序会影响性能（差异显著）

好顺序（通常更好）

- ① 简单 → 中等 → 复杂
- ② 格式一致
- ③ 标签分布合理



差顺序（可能很差）

- ① 格式混乱
- ② 难度跳跃大
- ③ 标签分布不均



Lu et al., 2021 发现：

仅改变示例顺序，性能会大幅波动；
有些顺序接近 SOTA，有些接近随机猜测！

示例：顺序影响（情感分类任务）

任务：判断评论情感（Positive / Negative）

新输入（待预测）

“The movie was surprisingly emotional.”



顺序 A（更好）

简单例子

Q: I love this movie.
A: Positive

中等例子

Q: The plot was slow but touching.
A: Positive

复杂例子

Q: The visual was stunning but the story was boring.
A: Negative



规律容易建立，预测更准确

顺序 B（更差）

复杂例子

Q: The visual was stunning but the story was boring.
A: Negative

简单例子

Q: I love this movie.
A: Positive

格式混乱

Q: Terrible acting.
Answer: Bad



规律混乱，预测容易出错

结果对比（GPT-3）

顺序 A 准确率

75%

顺序 B 准确率

30%



仅改变顺序，性能差距巨大！

现在(GPT-4/Claude/Gemini等):

现在 (GPT-4 / Claude / Gemini 等) : 影响下降, 但问题仍然存在



为什么改善了?

- ✓ 指令微调 (Instruction Tuning)
- ✓ 人类反馈强化学习 (RLHF)
- ✓ 大量对话数据
- ✓ 更强的意图理解能力
- ✓ 更好的泛化与鲁棒性



现在的体验

随便问也能懂
日常任务更稳定
对表达变化更不敏感



但这些问题仍然存在, 尤其在复杂场景中

- 复杂推理、代码、数学、Agent、工具调用等任务仍受示例选择影响
- 示例顺序仍会造成性能波动 (虽然比早期小)
- Few-shot 的作用从“教模型任务” → 更像“上下文控制与推理引导”

为什么提示词有效?

核心观点:模型在上下文中看到示例后,虽然没有更新任何参数,但会根据这些例子“临时学习”,从而更好地完成当前任务,这是一种隐式的学习方式。

1. 传统训练 (需要更新参数)



需要大量数据 + 长时间训练

2. 上下文学习 / Few-shot (不更新参数)

上下文中的示例 (Few-shot)

例子1: 输入 A → 输出 A'

例子2: 输入 B → 输出 B'

...

例子K: 输入 K → 输出 K'

(提供几个例子)

不改参数, 但临时“进入学习状态”



不需要训练数据和更新参数, 只靠上下文中的例子临时适应任务

为什么提示词有效？

核心观点:模型在上下文中看到示例后, 虽然没有更新任何参数, 但会根据这些例子“临时学习”, 从而更好地完成当前任务, 这是一种隐式的学习方式。

3. 模型为什么能“临时学习”? (简单理解)

(1) 关注示例中的关键点



模型会仔细看例子之间的
模式和关系

(2) 在内部形成“学习状态”



模型根据这些模式, 临时调整
自己的思考方式, 适应当前任务

(3) 用这种状态完成任务



因此, 模型能输出符合示例
风格和规律的答案

本质: 模型像“考试前看例题”, 考试时能举一反三, 但考完就忘了。

复杂任务中常用的提示变体

针对复杂任务（例如**多步骤**推理问题），已提出了多种流行的提示方法。

1. 逐步引导 Step by Step

核心思想：引导模型生成问题的**分步解法**，可以获得更准确的最终答案
(Wei et al. 2022)

一个简单又有效的解决方案！

在模型回答前的提示中添加“让我们一步一步来思考”

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?

A: The answer (arabic numerals) is

(Output) 8 ✗

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?

A: **Let's think step by step.**

(Output) *There are 16 balls in total. Half of the balls are golf balls. That means that there are 8 golf balls. Half of the golf balls are blue. That means that there are 4 blue golf balls.* ✓

循序渐进的思考方式行之有效

	Arithmetic					
	SingleEq	AddSub	MultiArith	GSM8K	AQUA	SVAMP
zero-shot	74.6/ 78.7	72.2/77.0	17.7/22.7	10.4/12.5	22.4/22.4	58.8/58.7
Step-by Step	78.0/78.7	69.6/74.7	78.7/79.3	40.7/40.5	33.5/31.9	62.1/63.7
	Common Sense		Other Reasoning Tasks		Symbolic Reasoning	
	Common SenseQA	Strategy QA	Date Understand	Shuffled Objects	Last Letter (4 words)	Coin Flip (4 times)
zero-shot	68.8/72.6	12.7/ 54.3	49.3/33.6	31.3/29.7	0.2/-	12.8/53.8
Step-by Step	64.6/64.0	54.8/52.3	67.5/61.8	52.4/52.9	57.6/-	91.4/87.8

2. 思维链提示法 (CoT)

可以通过在提示中加入**演示**和**自我解释** (Wei et al. 2022) , 并允许模型在生成答案之前先生成该自我解释, 来改进这一思路。这被称为“**思维链**”(CoT) 提示法。

Standard Prompting

Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The answer is 27. ❌

Chain of Thought Prompting

自我解释演示

Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. $5 + 6 = 11$. The answer is 11.


Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The cafeteria had 23 apples originally. They used 20 to make lunch. So they had $23 - 20 = 3$. They bought 6 more apples, so they have $3 + 6 = 9$. The answer is 9. ✅

思维链提示

- Finetuned GPT-3 175B
- Prior best
- PaLM 540B: standard prompting
- PaLM 540B: chain-of-thought prompting



Math Word Problems (free response)

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. $5 + 6 = 11$. The answer is 11.

Math Word Problems (multiple choice)

Q: How many keystrokes are needed to type the numbers from 1 to 500?
Answer Choices: (a) 1156 (b) 1392 (c) 1480 (d) 1562 (e) 1788

A: There are 9 one-digit numbers from 1 to 9. There are 90 two-digit numbers from 10 to 99. There are 401 three-digit numbers from 100 to 500. $9 + 90(2) + 401(3) = 1392$. The answer is (b).

CSQA (commonsense)

Q: Sammy wanted to go to where the people were. Where might he go?
Options: (a) race track (b) populated areas (c) desert (d) apartment (e) roadblock

A: The answer must be a place with a lot of people. Race tracks, desert, apartments, and roadblocks don't have a lot of people, but populated areas do. So the answer is (b).

StrategyQA

Q: Yes or no: Would a pear sink in water?

A: The density of a pear is about 0.6 g/cm³, which is less than water. Thus, a pear would float. So the answer is no.

Date Understanding

Q: The concert was scheduled to be on 06/01/1943, but was delayed by one day to today. What is the date 10 days ago in MM/DD/YYYY?

A: One day after 06/01/1943 is 06/02/1943, so today is 06/02/1943. 10 days before today is 05/23/1943. So the answer is 05/23/1943.

Sports Understanding

Q: Is the following sentence plausible? "Joao Moutinho caught the screen pass in the NFC championship."

A: Joao Moutinho is a soccer player. The NFC championship is part of American football, not soccer. So the answer is no.

SayCan (Instructing a robot)

Human: How would you bring me something that isn't a fruit?

Explanation: the user wants something to eat that isn't a fruit. An energy bar is not a fruit, so I will bring the user an energy bar.

Plan: 1. find(energy bar) 2. pick(energy bar) 3. find(user) 4. put(energy bar) 5. done().

Last Letter Concatenation

Q: Take the last letters of the words in "Lady Gaga" and concatenate them.

A: The last letter of "Lady" is "y". The last letter of "Gaga" is "a". Concatenating them is "ya". So the answer is ya.

Coin Flip (state tracking)

Q: A coin is heads up. Maybelle flips the coin. Shalonda does not flip the coin. Is the coin still heads up?

A: The coin was flipped by Maybelle. So the coin was flipped 1 time, which is an odd number. The coin started heads up, so after an odd number of flips, it will be tails up. So the answer is no.

1. 数学应用题 (Math Word Problems, 单选)

Q: 罗杰有 5 个网球。他又买了 2 罐网球。每罐有 3 个网球。
罗杰现在一共有多少个网球?

思考过程:

- ① 罗杰原来有 5 个网球。
- ② 买了 2 罐, 每罐 3 个, 所以新买的网球数是 $2 \times 3 = 6$ 。
- ③ 总数 = 原来的 5 个 + 新买的 6 个 = 11。

A: 罗杰一共有 11 个网球。

2. 数学应用题 (Math Word Problems, 多选)

Q: 从 1 到 500 的所有数字中, 一共需要按多少次按键?
选项: (a) 1156 (b) 1392 (c) 1480 (d) 1562 (e) 1788

思考过程:

- ① 1 到 9 是一位数, 共 9 个。
- ② 10 到 99 是两位数, 共 90 个。
- ③ 100 到 500 是三位数, 共 401 个。
- ④ 按键总数 = $9 \times 1 + 90 \times 2 + 401 \times 3 = 9 + 180 + 1203 = 1392$ 。

A: 答案是 (b) 1392。

3. 常识问答 (CSQA, 常识推理, 多选)

Q: 萨米想去人多的地方。他可能去哪里?
选项: (a) 赛车场 (b) 人口密集区 (c) 沙漠 (d) 公寓楼 (e) 路障

思考过程:

- ① 赛车场: 去的人有限, 不一定很拥挤。
- ② 沙漠: 人很少。
- ③ 公寓楼: 人可能较多, 但不一定最大。
- ④ 路障: 通常没人。
- ⑤ 人口密集区通常有很多人。

A: 最可能的地方是 (b) 人口密集区。

4. 策略问答 (StrategyQA, 是非题)

Q: 梨会沉在水里吗?

思考过程:

- ① 梨的密度大约是 0.6 g/cm^3 。
- ② 水的密度是 1 g/cm^3 。
- ③ 梨的密度小于水的密度, 所以会浮在水面上, 不会沉。

A: 答案是否定的 (不会沉)。

5. 日期理解 (Date Understanding)

Q: 这场音乐会原定于 1943 年 06 月 01 日举行, 但推迟了一天到今天。今天是 06 月 02 日, 那么 10 天前的日期是? (格式: MM/DD/YYYY)

思考过程:

- ① 原定 06/01/1943, 推迟一天到今天, 所以今天是 06/02/1943。
- ② 10 天前就是从 06/02/1943 往前推 10 天。
- ③ 06/02/1943 往前推 10 天是 05/23/1943。

A: 答案是 05/23/1943。

6. 体育理解 (Sports Understanding, 是非题)

Q: 以下句子是否合理? “若昂·穆蒂尼奥在 NFL 冠军赛中完成了一次接球。”

思考过程:

- ① 若昂·穆蒂尼奥是一名足球 (足球) 运动员。
- ② NFL 是美式橄榄球联赛, 不是足球。
- ③ 足球运动员不太可能在 NFL 冠军赛中接球。

A: 答案是否定的 (不合理)。

7. 机器人指答 (SayCan)

Q: 人类: 请帮我拿一个不是水果的东西。

思考过程:

- ① 用户想要可以吃的东西, 但不是水果。
- ② 能量棒 (能量棒) 可以吃, 且不是水果。
- ③ 选择去拿能量棒。

计划 (Plan):

1. 找到能量棒的位置
2. 拿起能量棒
3. 递给用户
4. 完成任务

A: 我会拿能量棒给用户。

8. 最后一个字母拼接 (Last Letter Concatenation)

Q: 取出单词 “Lady Gaga” 中每个单词的最后一个字母, 并将它们拼接起来。

思考过程:

- ① “Lady” 的最后一个字母是 “y”。
- ② “Gaga” 的最后一个字母是 “a”。
- ③ 将它们拼接起来得到 “ya”。

A: 答案是 ya。

9. 硬币翻转 (状态跟踪, Coin Flip)

Q: 硬币正面朝上。也许贝拉翻转了硬币。莎朗达没有翻转硬币。硬币现在正面朝上吗?

思考过程:

- ① 硬币一开始正面朝上。
- ② 贝拉翻转了 1 次, 正面变反面。
- ③ 莎朗达没有翻转, 所以保持现在的状态: 反面。
- ④ 一共翻转了 1 次 (奇数次), 所以硬币现在反面朝上。

A: 答案是否定的 (不是正面朝上)。

3. 从最少提示到最多提示 LtM (问题分解)

LtM = Least-to-Most Prompting

将复杂的问题分解为更小、更易于处理的子问题，以便逐一解决。

- 每个子问题的解决方案可能有助于解决下一个问题，从而形成循序渐进的解决问题过程。

阶段 1: 将问题分解为子问题

问题: 艾米爬到滑梯顶部需要 4 分钟, 滑下来需要 1 分钟。滑梯会在 15 分钟后关闭。她在滑梯关闭前可以滑多少次?

语言模型

思路: 要解决“她在滑梯关闭前可以滑多少次?”, 需要先解决:

子问题 1: 每次滑行需要多长时间?

子问题 2: 在关闭前可以滑多少次?

阶段 2: 依次解决子问题

子问题 1

艾米爬到滑梯顶部需要 4 分钟, 滑下来需要 1 分钟。滑梯会在 15 分钟后关闭。

问题: 每次滑行需要多长时间?

语言模型

回答: 艾米爬上去需要 4 分钟, 滑下来需要 1 分钟。

$4 + 1 = 5$, 所以每次滑行需要 5 分钟。

将子问题 1 的答案追加到原问题后, 进入子问题 2

子问题 2

艾米爬到滑梯顶部需要 4 分钟, 滑下来需要 1 分钟。滑梯会在 15 分钟后关闭。

问题: 每次滑行需要多长时间?

回答: 每次滑行需要 5 分钟。

问题: 在滑梯关闭前可以滑多少次?

语言模型

回答: 滑梯会在 15 分钟后关闭。每次滑行需要 5 分钟。

所以可以滑 $15 \div 5 = 3$ 次, 在关闭前可以滑 3 次。

4. 程序思维(PoT) (结构化思维)



语言模型被用于将推理步骤转化为 Python 程序。

这些程序由 Python 解释器执行，从而实现更准确、更复杂的数学问题求解能力

问题：斐波那契数列中，每个数都等于前面两个数之和。
假设前两个数分别为 0 和 1，求斐波那契数列中的第 50 个数是多少？

思维链 (CoT) 方法

第一个数是 0，第二个数是 1，因此：
第三个数是 $0+1=1$ 。
第四个数是 $1+1=2$ 。
第五个数是 $1+2=3$ 。
第六个数是 $2+3=5$ 。
第七个数是 $3+5=8$ 。
第八个数是 $5+8=13$ 。
.....
(省略 1000 个 token)
第 50 个数是 32,432,268,459。

思维链 (CoT)

32,432,268,459 ❌

由于数值过大，长文本思维链容易出错，
得到的结果不正确。

程序思维 (PoT) 方法

```
length_of_fibonacci_sequence = 50 # 斐波那契数列长度为 50
fibonacci_sequence = np.zeros(length_of_) # 创建长度为 50 的数组
fibonacci_sequence[0] = 0 # 第一个数为 0
fibonacci_sequence[1] = 1 # 第二个数为 1
for i in range(2, length_of_fibonacci_sequence):
    fibonacci_sequence[i] = fibonacci_sequence[i-1] + \
        fibonacci_sequence[i-2] # 当前数等于前两个数之和
ans = fibonacci_sequence[-1] # 第 50 个数 (索引为 -1)
```

程序思维 (PoT)



python
12,586,269,025 ✓

使用程序计算，结果准确无误。

5. 可信思维链推理 Faithful CoT

问题

罗伊斯单独粉刷一栋房子所需的时间，比罗布单独粉刷所需时间的 2 倍多 40 分钟。
如果罗布需要 2 小时，罗伊斯需要多少分钟？

标准提示 (Standard Prompting)

模型输出

答案是 4 小时 20 分钟。



思维链提示 (CoT Prompting) (Wei 等, 2022)

模型输出

罗伊斯比罗布的时间多 40 分钟，
也就是罗伊斯的时间 = $2 \times 2 + 40$
= $80 + 40 = 120$ 分钟。

答案是 120。



由简入繁提示 (Least-to-Most Prompting) (Zhou 等, 2023)

模型输出

要回答这个问题，我们需要先知道：

Q1. 罗布单独粉刷需要多少分钟？
罗布需要 2 小时。

Q2. 罗伊斯单独粉刷需要多少分钟？
罗伊斯比罗布的 2 倍多 40 分钟。

最终答案：罗伊斯需要多少分钟？
罗伊斯 = $2 \times 2 \text{ 小时} + 40 \text{ 分钟}$
= $4 \text{ 小时} + 40 \text{ 分钟} = 84 \text{ 分钟}$ 。

答案是 84。



可信思维链推理 (Faithful CoT, 本文方法)

模型输出

为了回答这个问题，编写一个 Python 程序来解决以下子问题：
1. 罗布单独粉刷需要多少分钟？
(独立子问题，已知：罗布需要 2 小时)

```
minutes_rob = 2 * 60
```

2. 罗伊斯单独粉刷需要多少分钟？
(依赖子问题，已知：罗伊斯比罗布 2 倍多 40 分钟)

```
minutes_royce = minutes_rob * 2 + 40
```

3. 最终答案：罗伊斯需要多少分钟？
(依赖子问题，已知：②)

```
answer = minutes_royce
```

```
>>>  Python 解释器 >>> 280
```



提示策略的比较

Model	Standard	CoT	LtM	PoT	FCoT
Codex	57.1	81.3	74.3	80.0	83.4
GPT-3.5.turbo	64.9	77.6	77.6	72.5	76.8
GPT-4	79.3	88.3	87.3	84.4	90.9
LLaMA-7B	40.1	56.4	46.0	47.4	50.2
LLaMA-13B	43.2	66.8	58.2	56.9	62.2
LLaMA-70B	58.0	82.0	73.3	73.6	77.0
Mistral-7B	49.9	73.5	61.9	66.5	71.2
Mistral-7B-instruct	43.7	63.6	56.0	60.0	67.1

各种大型语言模型在所有数据集上的平均准确率 (%)

Lyu等人 (2024) 开展了一项研究，在九个推理数据集上对比了多种策略：

- 总体而言，很难断定哪种提示策略在特定任务更好，因为每种策略都是针对特定类型的任务设计的。
- **包含中间步骤的**提示策略比**直接预测答案**的效果更好。

一个有用的技巧： 自洽性


我们通常使用贪婪解码（温度 $T = 0$ ）

- 生成多种输出（ $T > 0$ ）：
- 抽样 n 条候选推理路径及其对应的最终数值答案（ r_i, a_i ）
- 取**最一致（最频繁）**的答案：

$$\arg \max_a \sum_{i=1}^n \mathbb{1}(a_i = a)$$

思维链提示

(Chain-of-Thought Prompting)



自洽性 (Self-Consistency)

