

AI 如何从语言模型演变为 世界模型

什么是多模态

— 让我们从最简单的概念开始。

什么是多模态？

多模态行为与信号



语言 (Language)

- 词汇 (Lexicon)
 - 词语
- 语法 (Syntax)
 - 词性 (如名词、动词等)
 - 句法依赖关系
- 语用 (Pragmatics)
 - 话语行为 (如提问、请求等)



声音 (Acoustic)

- 音韵 (Prosody)
 - 语调 (Intonation)
 - 音色 / 音质 (Voice quality)
- 声学表达 (Vocal expressions)
 - 笑声、叹息、呻吟等



视觉 (Visual)

- 手势 (Gestures)
 - 头部手势
 - 眼部手势
 - 手臂手势



- 身体语言 (Body language)
 - 身体姿态
 - 人际距离 (Proxemics)



- 眼神交流 (Eye contact)
 - 头部注视 (Head gaze)
 - 眼睛注视 (Eye gaze)



- 面部表情 (Facial expressions)
 - 面部动作单元 (FACS)
 - 微笑、皱眉等表情



触觉 (Touch)

- 触觉反馈 (Haptics)
- 运动 / 触摸 (Motion)



生理 (Physiological)

- 皮肤电导 (Skin conductance)
- 心电图 (Electrocardiogram)




移动设备 (Mobile)

- GPS 位置 (GPS location)
- 加速度计 (Accelerometer)
- 光照传感器 (Light sensors)




多模态信息通过融合多种行为与信号，帮助AI更全面地理解人类意图、情绪和环境，从而实现更自然、准确和智能的交互。



人类能够同时处理**多模态**信息

为什么是多模态？

许多用例在，尤其是那些涉及多种数据模态的行业，例如医疗保健、机器人技术、电子商务、零售、游戏等。



什么是多模态？

(2) Prompt:

Describe the pointed region in the image.

Method	Validation set								Test set							
	in.		near.		out.		overall		in.		near.		out.		overall	
	C	S	C	S	C	S	C	S	C	S	C	S	C	S	C	S
OSCAR	85.4	11.9	84.0	11.7	80.3	10.0	83.4	11.4	84.8	12.1	82.1	11.5	73.8	9.7	80.9	11.3
Human	84.4	14.3	85.0	14.3	95.7	14.0	87.1	14.2	80.6	15.0	84.6	14.7	91.6	14.2	85.3	14.6
VIVO	92.2	12.9	87.8	12.6	87.5	11.5	88.3	12.4	89.0	12.9	87.8	12.6	80.1	11.1	86.6	12.4
ViaVL	103.7	13.7	95.6	13.4	83.8	11.9	94.3	13.1	98.0	13.6	95.2	13.4	78.0	11.5	92.5	13.1
UFO	103.9	14.5	95.5	13.8	83.5	12.3	94.3	13.6	98.9	14.3	94.7	13.9	77.9	12.1	92.3	13.6
mPLUG	-	-	-	-	-	-	114.8	14.8	-	-	-	-	-	-	-	-
SinVLM	113.7	-	110.9	-	115.2	-	115.2	-	113.7	-	110.9	-	115.2	-	115.2	-
LEMON	118.0	15.4	116.3	15.1	120.2	14.5	117.3	15.0	112.8	15.2	115.5	15.1	110.1	13.7	114.3	14.9
UniversalCap	123.2	15.0	121.5	15.3	123.4	14.4	122.1	15.0	118.9	15.4	120.6	15.3	114.3	14.1	119.3	15.1
CoCa	-	-	-	-	-	-	122.4	15.5	-	-	-	-	-	-	120.6	15.5
GIT ₀	100.7	13.8	97.7	13.5	89.6	12.5	96.6	13.4	-	-	-	-	-	-	-	-
GIT _L	107.7	14.9	107.8	14.5	102.5	13.7	106.9	14.4	-	-	-	-	-	-	-	-
GIT	120.8	16.3	124.1	16.0	127.1	15.7	125.5	16.0	122.4	16.2	123.9	16.0	122.0	15.7	123.4	15.9
GIT2	126.9	16.1	125.8	16.2	130.6	15.8	126.9	16.1	124.2	16.4	125.5	16.1	122.3	15.6	124.8	16.1

GPT-4V:

The highlighted red region in the image is a table cell that contains a numerical value of 122.3. It is located in the "Test set" section of the table, under the "out" column and the "GIT2" row. This value represents the overall performance metric for the GIT2 method on the test set, in the "out" category.

Prompt:

Localize each person in the image using bounding box. What is the image size of the input image?



GPT-4V:

The image size of the input image is 1000 x 333 pixels.

Bounding boxes for each person:

- Person 1 (leftmost): (x1, y1) = (22, 108), (x2, y2) = (170, 300)
- Person 2: (x1, y1) = (200, 80), (x2, y2) = (290, 270)
- Person 3: (x1, y1) = (350, 70), (x2, y2) = (460, 280)
- Person 4: (x1, y1) = (540, 80), (x2, y2) = (640, 270)
- Person 5 (rightmost): (x1, y1) = (760, 100), (x2, y2) = (920, 290)

Note: These bounding box coordinates are approximate and may not be exact.

Visualization of Detected Bbox:



Prompt:

Which wisdom tooth is hardest to remove?



Note: Same query image as shown above, resized to save space

GPT-4V:

The lower wisdom teeth, especially those that are impacted, are typically considered the hardest to remove. This is because the lower jawbone is denser than the upper jawbone, and the impacted wisdom teeth may be more difficult to access. Additionally, the roots of the lower wisdom teeth are often longer and more curved than those of the upper wisdom teeth, making them more challenging to remove.

Prompt:

Count the number of apples in the image.



GPT-4V:

There are 7 apples in the image.

GPT-4V的一些酷炫多模态应用案例

第一代：CLIP 与对齐时代

为什么需要图文对齐

为什么 ChatGPT 一开始看不懂图片？




CLIP 核心思想

1. 图像编码器 (Image Encoder)




图像
编码器

图像向量 (特征)



文本向量 (特征)




2. 文本编码器 (Text Encoder)

文本
编码器

"a dog"
"a cat"
"a red car"
"a mountain
and lake"
...

3. 计算相似度 (相似度矩阵)



正确配对 (对角线)
相似度高
→ 拉近距离

错误配对 (非对角线)
相似度低
→ 推远距离

训练目标: 让正确的图文靠近, 错误的图文远离

举例说明

✓ 正确配对 (靠近)



"a dog"

距离近, 语义相似



"a cat"

距离近, 语义相似

✗ 错误配对 (远离)



"a red car"

距离远, 语义不相似



"a cat"

距离远, 语义不相似

★ 通过大量图文配对数据训练, CLIP 学会了图像和语言的对应关系。

1 从输入到 Embedding (Encoder 输出)

CLIP 首先将文本和图像分别通过各自的 Encoder，得到初始的向量表示 (Embedding)。

1.1 文本输入

happy
hippie
hamster

文本被分词为 token 序列



Text
Encoder

(如 Transformer)



1.2 文本 Embedding (Encoder 输出)



(1 × 4)

记为 $t \in \mathbb{R}^{1 \times D_t}$

$D_t = 4$ (文本 Encoder 的输出维度)

形状 (Shape) 说明:

$$t \in \mathbb{R}^{1 \times D_t}$$

这里 $D_t = 4$

因此 t 的形状为 (1 × 4)

即一行四列的向量

1.3 图像输入



图像被分割为像素块 (patch) 序列



Image
Encoder

(如 ViT / CNN)



1.4 图像 Embedding (Encoder 输出)



(1 × 5)

记为 $v \in \mathbb{R}^{1 \times D_v}$

$D_v = 5$ (图像 Encoder 的输出维度)

形状 (Shape) 说明:

$$v \in \mathbb{R}^{1 \times D_v}$$

这里 $D_v = 5$

因此 v 的形状为 (1 × 5)

即一行五列的向量

2 投影到共同多模态空间 (Projection)

将文本和图像的 embedding 分别通过各自的 Projection Matrix 投影到同一维度的多模态空间 $\mathbb{R}^D$ 。

2.1 文本 Embedding (来自 Page 1)

文本 embedding 向量 $t \in \mathbb{R}^{1 \times 4}$

$$t = \begin{bmatrix} 1 & 2 & 3 & 4 \end{bmatrix}$$

形状: (1×4)

2.2 文本 Projection Matrix W_t

$$W_t \in \mathbb{R}^{4 \times 3}$$

$$W_t = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

形状: (4×3)

2.3 矩阵乘积 (投影到多模态空间)

$$t_{\text{proj}} = t \times W_t$$

$$(1 \times 4) \times (4 \times 3) = (1 \times 3)$$

计算过程:

第1维: $1 \times 1 + 2 \times 0 + 3 \times 1 + 4 \times 0 = 4$

第2维: $1 \times 0 + 2 \times 1 + 3 \times 1 + 4 \times 1 = 9$

第3维: $1 \times 1 + 2 \times 1 + 3 \times 0 + 4 \times 0 = 3$

2.4 文本多模态 embedding (输出)

$$t_{\text{multi}} \in \mathbb{R}^{1 \times 3}$$

$$t_{\text{multi}} = \begin{bmatrix} 4 & 9 & 3 \end{bmatrix}$$

形状: (1×3)

$$D = 3$$

(多模态空间的维度)

说明: 文本 embedding 维度 $D_t = 4$, 通过投影矩阵 $W_t \in \mathbb{R}^{4 \times 3}$, 映射到维度 $D = 3$ 的多模态空间。

2.5 图像 Embedding (来自 Page 1)

图像 embedding 向量 $v \in \mathbb{R}^{1 \times 5}$

$$v = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 \end{bmatrix}$$

形状: (1×5)

2.6 图像 Projection Matrix W_v

$$W_v \in \mathbb{R}^{5 \times 3}$$

$$W_v = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

形状: (5×3)

2.7 矩阵乘积 (投影到多模态空间)

$$v_{\text{proj}} = v \times W_v$$

$$(1 \times 5) \times (5 \times 3) = (1 \times 3)$$

计算过程:

第1维: $1 \times 1 + 2 \times 0 + 3 \times 1 + 4 \times 0 + 5 \times 1 = 9$

第2维: $1 \times 0 + 2 \times 1 + 3 \times 1 + 4 \times 1 + 5 \times 0 = 9$

第3维: $1 \times 1 + 2 \times 1 + 3 \times 0 + 4 \times 0 + 5 \times 1 = 8$

2.8 图像多模态 embedding (输出)

$$v_{\text{multi}} \in \mathbb{R}^{1 \times 3}$$

$$v_{\text{multi}} = \begin{bmatrix} 9 & 9 & 8 \end{bmatrix}$$

形状: (1×3)

$$D = 3$$

(多模态空间的维度)

说明: 图像 embedding 维度 $D_v = 5$, 通过投影矩阵 $W_v \in \mathbb{R}^{5 \times 3}$, 映射到维度 $D = 3$ 的多模态空间。

3 相似度计算 (Cosine Similarity)

在共同多模态空间 $\mathbb{R}^D$ 中，使用余弦相似度衡量文本和图像的语义相似程度。

3.1 文本多模态 embedding (来自 Page 2) 3.2 图像多模态 embedding (来自 Page 2)

$$\mathbf{t}_{\text{multi}} \in \mathbb{R}^{1 \times 3}$$

4	9	3
---	---	---

$$\mathbf{v}_{\text{multi}} \in \mathbb{R}^{1 \times 3}$$

9	9	8
---	---	---

3.3 余弦相似度公式

给定两个向量 $\mathbf{a}, \mathbf{b} \in \mathbb{R}^{1 \times D}$,

余弦相似度定义为：

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|}$$

符号说明

- $\mathbf{a} \cdot \mathbf{b}$: 向量点积
- $\|\mathbf{a}\|$: 向量 $\mathbf{a}$ 的 L_2 范数
- D : 多模态空间维度

本例中 $D = 3$

3.4 计算过程 (逐步展开)

① 计算点积 $\mathbf{t}_{\text{multi}} \cdot \mathbf{v}_{\text{multi}}$

$$\begin{aligned}\mathbf{t}_{\text{multi}} \cdot \mathbf{v}_{\text{multi}} &= 4 \times 9 + 9 \times 9 + 3 \times 8 \\ &= 36 + 81 + 24 = \mathbf{141}\end{aligned}$$

② 计算 $\|\mathbf{t}_{\text{multi}}\|$

$$\begin{aligned}\|\mathbf{t}_{\text{multi}}\| &= \sqrt{4^2 + 9^2 + 3^2} \\ &= \sqrt{16 + 81 + 9} \\ &= \sqrt{106}\end{aligned}$$

③ 计算 $\|\mathbf{v}_{\text{multi}}\|$

$$\begin{aligned}\|\mathbf{v}_{\text{multi}}\| &= \sqrt{9^2 + 9^2 + 8^2} \\ &= \sqrt{81 + 81 + 64} \\ &= \sqrt{226}\end{aligned}$$



3.5 余弦相似度结果

$$\begin{aligned}\cos(\mathbf{t}_{\text{multi}}, \mathbf{v}_{\text{multi}}) &= \frac{141}{\sqrt{106} \sqrt{226}} \\ &= \frac{141}{\sqrt{106 \times 226}} \\ &= \frac{141}{\sqrt{23956}} \\ &\approx \frac{141}{154.79} \approx \mathbf{0.910}\end{aligned}$$

4 Softmax 概率（以图像为查询）

以图像作为查询，从共同多模态空间中的文本分支向量进行 Softmax，得到每个文本的匹配概率分布。

4.1 共同多模态空间中的向量

来自 Page 2 的多模态 embedding（输出）

文本分支向量 $t_{\text{multi}} \in \mathbb{R}^{1 \times 3}$

图像分支向量 $v_{\text{multi}} \in \mathbb{R}^{1 \times 3}$
(查询 Query)

文本 (Token)	T_1	T_2	T_3	维度	D_1	D_2	D_3
向量值	4	9	3	向量值	9	9	8

形状: (1×3)

形状: (1×3)

4.2 Softmax 公式

对第 i 个文本 (Token T_i) 的概率:

$$p_i = \frac{e^{s_i/\tau}}{\sum_{k=1} e^{s_k/\tau}}$$

其中:

- $s_i = v_{\text{multi}} \cdot t_i$: 图像向量与第 i 个文本向量的点积
- τ : 温度系数 (本例取 $\tau = 1$)

4.3 计算点积 $s_i = v_{\text{multi}} \cdot t_i$

文本 (T_i)	文本向量 t_i	计算过程	点积 s_i
T_1	(4, 9, 3)	$9 \times 4 + 9 \times 9 + 8 \times 3$ $= 36 + 81 + 24$	141
T_2	(9, 9, 0)	$9 \times 9 + 9 \times 9 + 8 \times 0$ $= 81 + 81 + 0$	162
T_3	(3, 0, 3)	$9 \times 3 + 9 \times 0 + 8 \times 3$ $= 27 + 0 + 24$	51

4.4 计算 Softmax 概率 ($\tau = 1$)

文本 (T_i)	点积 s_i	$e^{s_i/\tau}$ (数值)	概率 p_i
T_1	141	$e^{141} \approx 7.2058 \times 10^{61}$	0.429
T_2	162	$e^{162} \approx 1.6860 \times 10^{70}$	0.811
T_3	51	$e^{51} \approx 1.4093 \times 10^{22}$	0.000

分母 (归一化因子)

$$\sum_{k=1}^3 e^{s_k} = e^{141} + e^{162} + e^{51} \approx 1.6860 \times 10^{70}$$

4.5 概率分布结果 (以图像为查询)

Softmax 概率向量 $p \in \mathbb{R}^{1 \times 3}$

文本 (Token)	T_1	T_2	T_3
概率 p_i	0.429	0.811	0.000

形状: (1×3)

匹配结果:

图像与文本 T_2 的匹配概率最高 (0.811)。

数值稳定性说明

由于指数函数数值很大，实际实现中通常使用 Log-Sum-Exp 技巧进行数值稳定计算:

1. 令 $m = \max(s_i) = 162$

$$2. p_i = \frac{e^{s_i - m}}{\sum_k e^{s_k - m}}$$

本例计算结果与直接计算一致。

5 训练目标：对比学习（Cross Entropy Loss）

目标是让正确的图文对相似度更高，错误的更低。使用对比学习的交叉熵损失（InfoNCE Loss）作为训练目标。

5.1 图像作为查询（以图找文）

5.1.1 Softmax 概率（来自 Page 4）

文本 (Token)	T_1	T_2	T_3
概率 $p_{i v}$	0.429	0.811	0.000

正确文本为 T_2 （索引为 2），其概率为 0.811。

5.1.2 损失计算（交叉熵）

$$L_{i2t} = -\log p_{i|v}(T_2) = -\log 0.811 = 0 \text{（保留三位小数）}$$

说明：

- L_{i2t} 表示以图像 v 为查询，正确匹配到文本 T_2 的损失；
- 若模型预测正确（概率接近 1），损失接近 0。

5.2 文本作为查询（以文找图）

5.2.1 Softmax 概率（以图像为候选）

图像 (Image)	I_1	I_2	I_3
概率 $p_{i t}$	0.333	0.667	0.000

正确图像为 I_2 （索引为 2），其概率为 0.667。

5.2.2 损失计算（交叉熵）

$$L_{t2i} = -\log p_{i|t}(I_2) = -\log 0.667 = 0.405 \text{（保留三位小数）}$$

说明：

- L_{t2i} 表示以文本 t_2 为查询，正确匹配到图像 I_2 的损失；
- 模型不确定时（概率较低），损失较大。

5.3 总损失（对称对比学习）

采用对称的对比学习目标，综合两种查询方式的损失：

$$\begin{aligned} L &= \frac{L_{i2t} + L_{t2i}}{2} \\ &= \frac{0 + 0.405}{2} = 0.203 \text{（保留三位小数）} \end{aligned}$$

其中： $L_{i2t} = 0$ ， $L_{t2i} = 0.405$

计算过程（详细展开）

$$\begin{aligned} L &= \frac{L_{i2t} + L_{t2i}}{2} \\ &= \frac{0 + 0.405}{2} \\ &= \frac{0.405}{2} \\ &= 0.2025 \approx \mathbf{0.203} \end{aligned}$$


💡 本页关键信息

- 以图找文的正确匹配为 T_2 ，概率 0.811，损失 0。
- 以文找图的正确匹配为 I_2 ，概率 0.667，损失 0.405。
- 总损失为两者的平均： $L = 0.203$ 。
- 损失越小，表示模型的匹配效果越好。

CLIP 计算流程图解（完整流程一览）

1 输入 → 2 编码器 → 3 投影到共同空间 → 4 计算相似度矩阵 → 5 Softmax 概率分布 → 6 对称对比学习损失

1 输入（批量数据）



2 投影到共同空间

使用可学习的线性投影
将特征映射到 D 维空间

文本投影矩阵 $W_t \in \mathbb{R}^{d_t \times D}$

...	...	...
...	...	...
...	...	...

图像投影矩阵 $W_i \in \mathbb{R}^{d_i \times D}$

...	...	...
...	...	...
...	...	...

投影并归一化 (L2 归一化)

$$V = \text{normalize}(E_T W_t) \in \mathbb{R}^{N \times D}$$

$$U = \text{normalize}(E_I W_i) \in \mathbb{R}^{N \times D}$$

(normalize: L2 归一化)

3 计算相似度矩阵

计算所有图像与文本的
余弦相似度（点积）

$$S = UV^T \quad \tau \in \mathbb{R}^{N \times N}$$

τ 为温度系数
(如 $\tau = 0.07$)

相似度矩阵 S (图像 $\times$ 文本)

	T_1	T_2	T_3
I_1	s_{11}	s_{12}	s_{13}
I_2	s_{21}	s_{22}	s_{23}
I_3	s_{31}	s_{32}	s_{33}

说明

- s_{ij} 表示图像 I_i 与文本 T_j 的相似度
- 数值越大，越相似

4 Softmax 概率分布 (按行对文本做 Softmax)

对每一行（每张图像）在文本维度
做 Softmax，得到图像→文本的
匹配概率分布

$$P_{i \rightarrow t} = \text{Softmax}(S, \text{dim} = 1) \\ \in \mathbb{R}^{N \times N}$$

图像→文本 概率矩阵 $P_{i \rightarrow t}$

	T_1	T_2	T_3
I_1	p_{11}	p_{12}	p_{13}
I_2	p_{21}	p_{22}	p_{23}
I_3	p_{31}	p_{32}	p_{33}

说明

- 每一行相加为 1
- 对角线元素 (p_{11}, p_{22}, p_{33}) 是正确匹配的概率

5 Softmax 概率分布 (按列对图像做 Softmax)

对每一列（每个文本）在图像维度
做 Softmax，得到文本→图像的
匹配概率分布

$$P_{t \rightarrow i} = \text{Softmax}(S, \text{dim} = 0) \\ \in \mathbb{R}^{N \times N}$$

文本→图像 概率矩阵 $P_{t \rightarrow i}$

	I_1	I_2	I_3
T_1	q_{11}	q_{12}	q_{13}
T_2	q_{21}	q_{22}	q_{23}
T_3	q_{31}	q_{32}	q_{33}

说明

- 每一列相加为 1
- 对角线元素 (q_{11}, q_{22}, q_{33}) 是正确匹配的概率

6 对称对比学习损失 (InfoNCE)

CLIP 使用对称的 InfoNCE 损失，
图像→文本 和 文本→图像 两个方向
的损失取平均作为最终训练目标

图像→文本 方向损失

$$L_{i \rightarrow t} = -\frac{1}{N} \sum_{i=1}^N \log p_{ii}$$

(对角线概率的负对数平均)

文本→图像 方向损失

$$L_{t \rightarrow i} = -\frac{1}{N} \sum_{j=1}^N \log q_{jj}$$

(对角线概率的负对数平均)

总损失 (双向平均)

$$L = \frac{L_{i \rightarrow t} + L_{t \rightarrow i}}{2}$$

(双向对称损失)


CLIP 为什么重要

CLIP 的突破：Zero-shot Vision（零样本视觉）



传统视觉模型只能识别固定的类别，而 CLIP 可以用自然语言作为“分类器”，实现**开放词汇识别**！

传统视觉分类模型（只能识别固定类别）



✗ 局限：只能识别训练时见过的有限类别

CLIP：语言作为“分类器”，实现开放词汇识别



✓ 优势：可以识别任意用语言描述的类别，实现零样本（Zero-shot）识别


为什么这是一个巨大突破？

1. 开放词汇



只要能用语言描述的东西，
CLIP 都有可能识别。

2. 无需额外训练




训练一次 CLIP，
就能适应很多不同的任务。

3. 把视觉带入语言世界



图像和语言共享同一个语义空间，
可以直接比较，理解更自然。

CLIP 的效果



CLIP 的局限

CLIP 的局限：它会“对齐”，但不会“理解和对话”



CLIP 擅长把图像和文字对齐，但它只是匹配相似度，无法真正理解图像内容，无法进行推理和对话。

✅ CLIP 能做的（对齐相关的任务）



判断图像与文字是否匹配



a dog



'a cat



Zero-shot 分类（开放词汇）



a chair



a table



a sofa



...



图文检索 / 语义搜索

mountains
with lake



...



❌ CLIP 不能做的（需要理解和推理的任务）



不会对话



问：这只狗在干什么？



CLIP：无法回答，只能匹配相似文字。



不会推理



问：为什么地面是湿的？



CLIP：无法推理因果关系。



不理解细节 / 背景



问：今天是什么场合？



CLIP：无法识别生日等场景含义。



不支持多轮对话



问：这幅图是什么地方？

问：那这里的天气怎么样？




CLIP：无法进行上下文关联的多轮对话。

第二代：Flamingo 与可视化聊天时代

Flamingo: 多模态大模型的曙光


从简化的角度来看，**Flamingo** = **CLIP** + 自回归语言模型

- 添加解码器语言模型。与CLIP不同，Flamingo能够生成文本响应。
- 图像编码器与语言模型之间的注意力交互



Flamingo 能够基于文本和图像生成文本响应

Flamingo的高级架构



从宏观层面来看，Flamingo 由两部分组成

- 视觉编码器 (负责“看图”) : Flamingo 使用一个类似 CLIP 的视觉模型，把图片转换成“视觉特征”。这个视觉模型已经提前训练好，因此在 Flamingo 中会被冻结，不再更新参数。
- 语言模型 (负责“说话”) : Flamingo 使用强大的语言模型 (如 Chinchilla) 生成文本。模型根据“图片 + 文本”共同生成下一个 token，本质上仍然是 Next Token Prediction。

数据

Flamingo used 4 datasets: 2 (image, text) pair datasets, 1 (video, text) pair dataset, and 1 interleaved image and text dataset.



Image-Text Pairs dataset



Video-Text Pairs dataset



Multi-Modal Massive Web (M3W) dataset

Dataset	Type	Size	How	Training weight
M3W	Interleaved image and text dataset	43M webpages	For each webpage, they sample a random subsequence of 256 tokens and take up to the first 5 images included in the sampled sequence.	1.0
ALIGN	(Image, text) pairs	1.8B pairs	Texts are alt-texts, averaging 12 tokens/text.	0.2
LTIP	(Image, text) pairs	312M pairs	Texts are long descriptions, averaging 20.5 tokens/text.	0.2
VTP	(Video, text) pairs	27M short videos	~22 seconds/video on average	0.03

第三代：指令优化与 LLaVA 时代

多模态大型语言模型中的指令微调

大型语言模型中的指令微调



基于强教师大型语言模型与混合人类数据的自我指导

大型语言模型中的指令微调 VS 多模态大型语言模型中的指令微调

1. 背景：文本模型的成功经验（Self-Instruct）



2. 多模态的问题：缺少“老师”



多模态大型语言模型中的指令微调

1 输入给 GPT-4 (图片 + 简单描述)

图片



图片描述 (可选)

一只狗在草地上奔跑，
看起来很开心。

2 GPT-4 (老师) 生成高质量问答

GPT-4



根据图片生成
高质量的问答对

3 生成多模态指令数据 (示例) (图 + 问题 + 回答)



问: 狗在做什么?
答: 狗在草地上奔跑。



问: 这张图的背景是什么?
答: 背景是绿色的草地和树木。



问: 如果狗想玩球, 它可能在做什么?
答: 它可能在追球或者等待球被扔出。



问: 这只狗看起来怎么样?
答: 它看起来很开心。

.....

4 构建大规模数据集



158K 条
多模态指令数据
(高质量)

5 指令微调 LLaVA 模型

视觉编码器

CLIP ViT-L



负责“看图”

+

大语言模型

Vicuna 等



负责“说话”

(连接器 / 投影层)



多模态聊天机器人


用户: 这只狗在做什么?
LLaVA: 它在草地上奔跑。

Flamingo VS LLaVA



LLaVA: 大型语言与视觉助手

一、模型结构 (Architecture)




二、两阶段训练 (Two-stage Training)



基于GPT的视觉教学数据生成

 **输入：图像 + 检测信息**

示例图像



检测结果（目标框信息）

1 SUV（黑色越野车） [0.681, 0.242, 0.774, 0.694]	5 行李箱（蓝色） [0.755, 0.413, 0.846, 0.692]
2 人（在车内） [0.630, 0.222, 0.686, 0.516]	6 行李箱（黑色） [0.758, 0.413, 0.845, 0.691]
3 人（正在装车） [0.444, 0.233, 0.487, 0.340]	7 自行车 [0.282, 0.363, 0.327, 0.442]
4 人（提行李） [0.384, 0.696, 0.485, 0.914]	8 背包 [0.100, 0.497, 0.173, 0.579]

上下文类型 1（图像描述）

- 人们正在将行李装入一辆黑色 SUV。
- 车辆停在地下停车场中，周围有多个行李和背包。
- 一些人靠近车辆，有的在车内，有的在后备箱附近。

.....



其他多模态大型语言模型：Qwen-VL





Figure 3: The training pipeline of the Qwen-VL series.


1 把图片切成小块 (patch)

例如把图片切成 $3 \times 3 = 9$ 个小块




2 每个小块变成向量 (线性投影)

每个 patch 通过线性层变成一个向量 (也就是一个 token)



3 和文字 token 拼接在一起

在图像 tokens 前面加上几个特殊标记, 再和文本 tokens 拼接




4 统一的 Transformer Decoder (大模型)

所有 tokens 一起输入同一个 Transformer, 让模型同时理解图片和文字



5 生成回答


模型根据图片和文本, 生成接下来的文字




CogVLM：图像特征和文本特征如何计算 Q、K、V 并参与注意力计算？

核心思想：图像 token 和文本 token 使用不同的 QKV 矩阵（参数不共享），但在同一个注意力空间中一起计算，实现跨模态交互。


1 图像处理：得到图像 token




2 文本处理：得到文本 token



3 拼接成统一的 token 序列




4 在 Fuyu Transformer Decoder 中计算注意力



关键点总结

- 1 图像 patch 经过 ViT 得到特征，再通过 MLP Adapter 映射到与文本相同的隐藏维度，得到图像 token。
- 2 文本通过词嵌入得到文本 token。
- 3 将图像 token 与文本 token 拼接成统一序列，加入特殊标记。
- 4 计算 Q、K、V 时：
 - 图像 token 使用图像专用的 QKV 矩阵 (紫色部分)
 - 文本 token 使用文本专用的 QKV 矩阵 (右侧白色部分)
 - 但在计算注意力时，所有 token 在同一注意力矩阵中相互作用！
- 5 经过多层 Decoder 后，自回归生成回答。

5 输出生成



为什么要分开 QKV？

图像特征与文本特征分布差异大，分开可以让模型更好地学习两种模态各自的表示，同时又能在注意力中充分融合。

其他多模态大型语言模型：CogVLM-Chat




Figure 3: The architecture of CogVLM. (a) The illustration about the input, where an image is processed by a pretrained ViT and mapped into the same space as the text features. (b) The Transformer block in the language model. The image features have a different QKV matrix and FFN. Only the **purple** parts are trainable.

第四代： **GPT-4V / GPT-4o** 时代

**我们是否已接近或超越了GPT-4?
就新功能的原型开发而言**

**仍存在巨大差距.....
在扩展能力方面**

GPT-4 在以下方面表现出色

- 阅读多张高分辨率图像、长序列
- 运用领域知识进行回应

GPT-4 visual input example, Pixel to Paper Summaries:

User Below is part of the InstructGPT paper. Could you read and summarize it to me?



GPT-4 The InstructGPT paper focuses on training large language models to follow instructions with human feedback. The authors note that making language models larger doesn't inherently make them better at following a user's intent. Large models can generate outputs that are untruthful, toxic, or simply unhelpful.

To address this issue, the authors fine-tune language models on a wide range of tasks using human feedback. They start with a set of labeler-written prompts and responses, then collect a dataset of labeler demonstrations of the desired model behavior. They fine-tune GPT-3 using supervised learning and then use reinforcement learning from human feedback to further fine-tune the model. The resulting model, called InstructGPT, shows improvements in truthfulness and reductions in toxic output generation while having minimal performance regressions on public NLP datasets.

The authors conclude that fine-tuning with human feedback is a promising direction for aligning language models with human intent.

User Could you explain the process described in Figure 2?


GPT-4 Figure 2 in the InstructGPT paper illustrates the three steps of their method:

1. Supervised fine-tuning (SFT): They collect demonstration data, which consists of labeler-written prompts and desired output behavior. This data is used to fine-tune GPT-3 with supervised learning.
2. Reward model (RM) training: They collect comparison data, where a labeler ranks the outputs from several model samples (from best to worst). This data is used to train the reward model.
3. Reinforcement learning using Proximal Policy Optimization (PPO): They optimize a policy against the reward model using reinforcement learning. For each new prompt sampled from the dataset, the policy generates an output. The reward model calculates a reward for the output, and the reward is used to update the policy using the PPO algorithm.

These three steps are iteratively performed to train the InstructGPT model, which aims to generate outputs that align better with human preferences and follow instructions more effectively.

GPT-4 visual input example, École Polytechnique Exam Question:

User Answer question I.1.a. Think step-by-step.



I.1. Dans cette première partie, on étudie le comportement du bolomètre en régime stationnaire, à la température de fonctionnement $T = T_0$.

I.1.a) Expliquez la température $T(x)$ en tout point du barreau conducteur repéré par son abscisse x ; on prendra $T(0) = T_0$ et $T(L) = T_b$.

GPT-4 To answer question I.1.a, we need to express the temperature $T(x)$ in every point of the conductive bar, which is characterized by the abscissa x . We are given that $T(0) = T_0$ and $T(L) = T_b$.

For a stationary regime, the heat equation for the one-dimensional heat conduction in the bar is:
$$d^2T/dx^2 = 0$$

Integrating once, we get:
$$dT/dx = C_1$$

Integrating a second time:
$$T(x) = C_1x + C_2$$

To determine the constants C_1 and C_2 , we use the boundary conditions:
 $T(0) = T_0$, which gives $C_2 = T_0$
 $T(L) = T_b$, which gives $C_1 = (T_b - T_0)/L$


Finally, the expression for $T(x)$ is:
$$T(x) = (T_b - T_0) * (x/L) + T_0$$

This represents a linear temperature profile along the conductive bar, with a slope of $(T_b - T_0)/L$.

Table 15. Example prompt demonstrating GPT-4's visual input capability. The prompt consists of a question which requires understanding a physics problem with a diagram written in French and solving it using chain-of-thought prompting.


GPT-4V 架构概念图

基于公开信息的合理推测



GPT-4o 架构概念图

OpenAI 在 GPT-4o System Card 里：明确写了：“same neural network”即：所有模态由同一个神经网络处理。




多模态大模型：范式演化图（基于公开信息的合理概括）

从“图文对齐” → “视觉增强 LLM” → “原生统一多模态”

第一代：图文对齐模型

代表：CLIP



📌 关键特点

- 图像和文本分别编码
- 只进行对齐，不生成内容
- 典型任务：零样本分类、检索

第二代：视觉增强 LLM

代表：GPT-4V / LLaVA / BLIP-2 / Flamingo 等



📌 关键特点

- 图像经编码器转成 Token，接入 LLM
- 本质仍是 LLM 为中心，输出主要是文本
- 典型任务：图像问答、OCR、图表理解等

第三代：原生统一多模态模型

代表：GPT-4o / Gemini 1.5 / 其他 Omni 模型



📌 关键特点

- 所有模态统一表示，统一建模
- 图文音视频都能理解、推理与生成
- 典型任务：实时语音对话、视频理解、跨模态生成等


对齐阶段
(理解：图像 ↔ 文本)

增强阶段
(理解：图像 → 文本)

统一阶段
(理解 + 生成：多模态 ↔ 多模态)

是否存在可以进行纹理化的视觉线索？

(a) Question: What is the difference in percentage between the years 1979 and 1986?



Qwen-VL

In 1979, the gross enrollment ratio in tertiary education is approximately 5%. In 1986, the gross enrollment ratio is approximately 1%. The absolute difference is: $5\% - 1\% = 4\%$. Therefore, the answer is 4%. ❌

Point-RFT

① The line representing Guinea's enrollment ratio starts at 5% in 1979.

② The line representing Guinea's enrollment ratio reaches 2% in 1986.

To find the difference, subtract the value in 1986 from the value in 1979: $5\% - 2\% = 3\%$.

The difference in percentage between the years 1979 and 1986 is 3%.

Therefore, the answer is 3. ✅

- 视觉锚定：指点中的思考

● 来源：Document Domain

● 至通用图形

Question: How many bar has a same value?

Freight transport K&L, Middle East, October 2019



Qwen-VL

3 bar has a same value.

Therefore, the answer is 3.

Point-RFT

① The bar representing Finland has a value of 0.01 million tonne-kilometres.

② The bar representing Hungary also has a value of 0.01 million tonne-kilometres.

Since both Finland and Hungary have the same value of 0.01 million tonne-kilometres, there are two bars with the same value.

Therefore, the answer is 2.

Question: Is the sum of all values in the Rep/Lean Rep more than Dem/Lean Dem?

Younger Americans more skeptical that U.S. impacts world problems positively

Workshop

U.S. impacts world problems positively

Total

Rep/Lean Rep

Dem/Lean Dem

U.S. impacts world problems positively

U.S. impacts world problems positively

U.S. impacts world problems positively

U.S. impacts world problems positively

U.S. impacts world problems positively

Qwen-VL

To determine if the sum of all values in the Rep/Lean Rep group is more than the sum of all values in the Dem/Lean Dem group, I will add up the values for each group and compare them. For Rep/Lean Rep: 19 (Conservative) + 24 (Mod/Lib) + 20 (Liberal) = 63. For Dem/Lean Dem: 17 (Conservative) + 10 (Mod/Lib) + 40 (Liberal) = 67. The sum for Rep/Lean Rep is 63, while the sum for Dem/Lean Dem is 67. Therefore, the sum of all values in the Rep/Lean Rep group is not more than the sum of all values in the Dem/Lean Dem group.

Therefore, the answer is No.

Point-RFT

① The Rep/Lean Rep size contains the values 19, 24, 20, 17, 10, and 40. The sum of these values is calculated as follows: $19 + 24 + 20 + 17 + 10 + 40 = 130$.

② The Dem/Lean Dem size contains the values 17, 10, 40, 19, 24, and 20. The sum of these values is calculated as follows: $17 + 10 + 40 + 19 + 24 + 20 = 130$.

Comparing the sums, 130 (Rep/Lean Rep) is not more than 130 (Dem/Lean Dem).

Therefore, the sum of all values in the Rep/Lean Rep is not more than the sum of all values in the Dem/Lean Dem.

Therefore, the answer is No.

Question: I am at Airport S. How can I get to Dongshankou?



Qwen-VL

From Airport S: Take the Orange Line (Line 3) towards Tianhe.

At Jiahewanggang Station: Change to the Blue Line (Line 2).

At Dongshankou Station: You will arrive at your destination.

Point-RFT

① Start at Airport S: This station is located at the top of the map, near the center.

Take Line 3: Line 3 is represented by the orange color. Follow the orange line from Airport S towards the center of the map.

Transfer at Guangzhou East Railway Station: At Guangzhou East Railway Station, transfer to Line 1, which is the yellow line.

Continue to Dongshankou: After transferring to Line 1, continue along the yellow line towards the bottom of the map.

Question: On April 21, weather will be?



Qwen-VL

The image shows the weather forecast for the week starting from April 16. However, the question asks about April 21.

Since the image only provides information up to April 21, we cannot determine the weather for April 21 from this image alone.

Point-RFT

① The image shows the weather forecast for the week starting from April 16. However, the question asks about April 21.

② ③ ④ ⑤ ⑥ To find the weather for April 21, we need to count 5 days from Monday, April 16. Counting forward, we have:

- April 17: Tuesday
- April 18: Wednesday
- April 19: Thursday
- April 20: Friday
- April 21: Saturday

According to the image, on April 21, the weather is forecasted to be 12°C with a partly sunny icon.

探索过程中会出现新的视觉内容吗？



这只狗是什么颜色的？

```
from PIL import Image
img = Image.open("input.jpg")
crop = img.crop(100, 100, 400, 400)
crop.save("output.jpg")
```

样本来源：“v*：多模态大型语言模型中的核心机制——引导式视觉搜索”方法
：“O3”，“通过图像进行思考”

未来趋势




1. 语言模型 (LLM)

主要能力：理解与生成语言

例：GPT-3 / GPT-4

• 预测下一个 Token



2. 多模态大模型 (MLLM)

主要能力：理解多种模态（文本/图像/音频/视频）

例：GPT-4V / GPT-4o

统一感知与理解



3. 多模态智能体 (Agent)

主要能力：理解、规划并执行任务

例：GUI Agent / Tool Use / Robotics

与环境交互，完成复杂任务



4. 世界模型 (World Model)

主要能力：构建世界内部模型，预测未来，规划行动

例：自动驾驶 / 机器人 / 通用智能体

在脑中模拟世界，做出最优决策

GPT-4o：原生多模态理解与实时交互




统一的多模态模型，端到端理解与生成

智能体：感知 → 规划 → 行动 → 反馈




通过工具使用与环境交互，完成目标任务

世界模型：在脑中模拟世界，预测未来，指导行动



理解世界的规律，预测未来可能发生的事情，选择最优行动

World Model: Genie 3



World Model

- 世界模型还没有真正实现，目前只是：“早期雏形”

已经做到：

- 空间连续性
- 短时物理规律
- 环境生成
- 视觉推理
- 初步规划能力

仍然做不到：

- 长时间稳定模拟
- 完整物理理解
- 真实因果建模
- 文明级长期预测
- 通用 AGI