

大语言模型第一次作业解答

学号：202533354 姓名：ZHOU MINGYUAN

第一部分：统计语言模型（二元）

训练语料为：

I love NLP
I love deep learning
I enjoy NLP
deep learning is fun

其中 $\langle s \rangle$ 表示句子开始符号， $\langle /s \rangle$ 表示句子结束符号。词汇表为

$$\mathcal{V} = \{I, \text{love}, \text{enjoy}, \text{NLP}, \text{deep}, \text{learning}, \text{is}, \text{fun}\}, \quad |\mathcal{V}| = 10.$$

问题 1：统计二元频率

题干：根据语料统计指定二元组和词的出现次数。

答案：

二元组	(I, love)	(love, NLP)	(love, deep)	(deep, learning)	(learning, is)
count	2	1	1	2	1

$\text{count}(I) = 3, \quad \text{count}(\text{love}) = 2, \quad \text{count}(\text{deep}) = 2.$

问题 2：计算条件概率

题干：计算 $P(\text{love} | I)$ 、 $P(\text{NLP} | \text{love})$ 、 $P(\text{deep} | \text{love})$ 、 $P(\text{is} | \text{learning})$ 。

答案：使用最大似然估计：

$$P(w_2 | w_1) = \frac{\text{count}(w_1, w_2)}{\text{count}(w_1)}.$$
$$P(\text{love} | I) = \frac{\text{count}(I, \text{love})}{\text{count}(I)} = \frac{2}{3},$$
$$P(\text{NLP} | \text{love}) = \frac{\text{count}(\text{love}, \text{NLP})}{\text{count}(\text{love})} = \frac{1}{2},$$
$$P(\text{deep} | \text{love}) = \frac{\text{count}(\text{love}, \text{deep})}{\text{count}(\text{love})} = \frac{1}{2},$$
$$P(\text{is} | \text{learning}) = \frac{\text{count}(\text{learning}, \text{is})}{\text{count}(\text{learning})} = \frac{1}{2}.$$

问题 3：未出现二元

题干：计算 $P(\text{fun} \mid \text{I})$ ，并说明为什么该概率为 0。

答案：

$$P(\text{fun} \mid \text{I}) = \frac{\text{count}(\text{I}, \text{fun})}{\text{count}(\text{I})} = \frac{0}{3} = 0.$$

训练语料中从未出现二元组 (I, fun) ，因此在未平滑的最大似然估计中，该条件概率为 0。

问题 4：Add-1 Smoothing

题干：使用 Add-1 smoothing 计算 $P(\text{love} \mid \text{I})$ 、 $P(\text{NLP} \mid \text{love})$ 、 $P(\text{deep} \mid \text{love})$ 、 $P(\text{fun} \mid \text{I})$ 。

答案：Add-1 smoothing 的公式为

$$P_{\text{add-1}}(w_2 \mid w_1) = \frac{\text{count}(w_1, w_2) + 1}{\text{count}(w_1) + |\mathcal{V}|}.$$

代入 $|\mathcal{V}| = 10$ ：

$$\begin{aligned} P(\text{love} \mid \text{I}) &= \frac{2 + 1}{3 + 10} = \frac{3}{13}, \\ P(\text{NLP} \mid \text{love}) &= \frac{1 + 1}{2 + 10} = \frac{2}{12} = \frac{1}{6}, \\ P(\text{deep} \mid \text{love}) &= \frac{1 + 1}{2 + 10} = \frac{2}{12} = \frac{1}{6}, \\ P(\text{fun} \mid \text{I}) &= \frac{0 + 1}{3 + 10} = \frac{1}{13}. \end{aligned}$$

问题 5：计算句子概率

题干：使用平滑后的二元模型计算句子概率

$$P(\text{I love NLP}) = P(\text{I} \mid \langle s \rangle) P(\text{love} \mid \text{I}) P(\text{NLP} \mid \text{love}).$$

答案：

$$P(\text{I} \mid \langle s \rangle) = \frac{\text{count}(\langle s \rangle, \text{I}) + 1}{\text{count}(\langle s \rangle) + |\mathcal{V}|} = \frac{3 + 1}{4 + 10} = \frac{2}{7}.$$

因此：

$$P(\text{I love NLP}) = \frac{2}{7} \times \frac{3}{13} \times \frac{1}{6} = \frac{1}{91}.$$

第二部分：神经网络语言模型

问题：前向计算与 Softmax

题干：已知输入词映射为

$$\text{I} \mapsto (1, 0), \quad \text{deep} \mapsto (2, 1).$$

要求写出输入矩阵 x ，计算隐层 $h = xW + b$ ，计算输出层得分 s ，使用 softmax 计算候选词概率，并给出预测词。

答案：

输入矩阵为

$$x = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix}.$$

根据题目给出的权重和偏置，隐层计算结果为

$$h = xW + b = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

输出层候选词得分记为

$$s = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{bmatrix}.$$

令 softmax 的归一化因子为

$$Z = e^1 + e^2 + e^3 + e^4 + e^5.$$

则候选词概率向量为

$$p = \text{softmax}(s) = \begin{bmatrix} \frac{e^1}{Z} \\ \frac{e^2}{Z} \\ \frac{e^3}{Z} \\ \frac{e^4}{Z} \\ \frac{e^5}{Z} \end{bmatrix}.$$

由于最大得分为 5，对应概率最大，因此预测词为 learning。