

大语言模型第三次作业解答

学号：202533354 姓名：ZHOU MINGYUAN

作业 3：FlashAttention 分块注意力计算

背景：某大语言模型在生成第 4 个 token 后的下一个词时，需要计算当前位置对前面 token 的注意力。序列为：

位置	1	2	3	4
Token	我	喜欢	学习	AI

已知

$$\mathbf{q} = [1, 2],$$

$$\mathbf{k}_1 = [1, 0], \quad \mathbf{k}_2 = [0, 1], \quad \mathbf{k}_3 = [1, 1], \quad \mathbf{k}_4 = [2, 0],$$

$$\mathbf{v}_1 = [1, 0], \quad \mathbf{v}_2 = [0, 2], \quad \mathbf{v}_3 = [1, 1], \quad \mathbf{v}_4 = [2, 1].$$

分块读取方式为：Block 1 包含 token 1、token 2；Block 2 包含 token 3、token 4。

第 1 问：计算 Attention Score

题干：计算 $q\mathbf{k}_i^T$ ，求 $[a_1, a_2, a_3, a_4]$ ，并说明当前 token 最关注哪个历史 token。

答案：

$$a_1 = \mathbf{q}\mathbf{k}_1^T = 1 \cdot 1 + 2 \cdot 0 = 1,$$

$$a_2 = \mathbf{q}\mathbf{k}_2^T = 1 \cdot 0 + 2 \cdot 1 = 2,$$

$$a_3 = \mathbf{q}\mathbf{k}_3^T = 1 \cdot 1 + 2 \cdot 1 = 3,$$

$$a_4 = \mathbf{q}\mathbf{k}_4^T = 1 \cdot 2 + 2 \cdot 0 = 2.$$

因此

$$[a_1, a_2, a_3, a_4] = [1, 2, 3, 2].$$

最大分数为 $a_3 = 3$ ，所以当前位置最关注第 3 个历史 token，即“学习”。

第 2 问：使用 Online Softmax 处理 Block 1

题干：Block 1 包含 token 1 和 token 2，对应分数为 $[1, 2]$ 。求当前最大值 m 、当前指数和 ℓ 、当前输出向量 $\mathbf{o}$ 。

答案：

$$m_1 = \max(1, 2) = 2.$$

为了数值稳定，Online Softmax 使用相对最大值的指数和：

$$\ell_1 = e^{1-m_1} + e^{2-m_1} = e^{-1} + 1.$$

Block 1 的归一化输出为

$$\mathbf{o}_1 = \frac{e^{1-m_1}\mathbf{v}_1 + e^{2-m_1}\mathbf{v}_2}{\ell_1} = \frac{e^{-1}[1, 0] + [0, 2]}{e^{-1} + 1}.$$

写成只含 e 的形式：

$$\mathbf{o}_1 = \left[\frac{1}{e+1}, \frac{2e}{e+1} \right].$$

第 3 问：处理 Block 2

题干：Block 2 包含 token 3 和 token 4，对应分数为 $[3, 2]$ 。更新最大值、指数和、输出向量。

答案：更新最大值：

$$m_2 = \max(m_1, 3, 2) = 3.$$

更新指数和：

$$\begin{aligned} \ell_2 &= \ell_1 e^{m_1-m_2} + e^{3-m_2} + e^{2-m_2} \\ &= (1 + e^{-1})e^{-1} + 1 + e^{-1} \\ &= 1 + 2e^{-1} + e^{-2}. \end{aligned}$$

将旧块分子按新最大值缩放，再加入 Block 2：

$$\begin{aligned} \mathbf{n}_2 &= e^{1-3}\mathbf{v}_1 + e^{2-3}\mathbf{v}_2 + e^{3-3}\mathbf{v}_3 + e^{2-3}\mathbf{v}_4 \\ &= e^{-2}[1, 0] + e^{-1}[0, 2] + [1, 1] + e^{-1}[2, 1] \\ &= [1 + 2e^{-1} + e^{-2}, 1 + 3e^{-1}]. \end{aligned}$$

因此

$$\mathbf{o}_2 = \frac{\mathbf{n}_2}{\ell_2} = \left[1, \frac{1 + 3e^{-1}}{1 + 2e^{-1} + e^{-2}} \right] = \left[1, \frac{e^2 + 3e}{e^2 + 2e + 1} \right].$$

第 4 问：给出最终 Attention 输出

题干：给出最终 Attention 输出，并说明当前位置更偏向哪些历史词信息。

答案：对分数 $[1, 2, 3, 2]$ 做 softmax。为避免近似计算，将最大值 3 平移到指数中：

$$\text{softmax}([1, 2, 3, 2]) = \frac{[e^{-2}, e^{-1}, 1, e^{-1}]}{1 + 2e^{-1} + e^{-2}}.$$

等价地，乘以 e^2 得

$$\text{softmax}([1, 2, 3, 2]) = \frac{[1, e, e^2, e]}{1 + 2e + e^2}.$$

因此最终输出为

$$\begin{aligned} \mathbf{o} &= \frac{1 \cdot \mathbf{v}_1 + e \cdot \mathbf{v}_2 + e^2 \cdot \mathbf{v}_3 + e \cdot \mathbf{v}_4}{1 + 2e + e^2} \\ &= \left[1, \frac{e^2 + 3e}{1 + 2e + e^2} \right]. \end{aligned}$$

权重最大的项是 $e^2 \cdot \mathbf{v}_3$ ，因此当前位置最偏向“学习”的语义信息；其次融合“喜欢”和“AI”的信息，因为 token 2 与 token 4 的分数相同，权重同为 $e/(1 + 2e + e^2)$ 。

第 5 问：理解题

题干：为什么 FlashAttention 不需要保存完整的 4×4 attention 矩阵？

答案：FlashAttention 按 block 读取 Q, K, V ，在每个 block 中即时计算 attention score，并用 Online Softmax 维护当前最大值 m 、指数和 ℓ 以及累计输出 $\mathbf{o}$ 。因此它只需要保存当前 block 的局部中间量和跨 block 的累计统计量，而不需要把所有 token 两两之间的 attention score 全部写入显存。

本题中，只需在两个 block 之间持续更新

$$(m, \ell, \mathbf{o})$$

即可得到最终 attention 输出；完整的 4×4 attention 矩阵并不是最终结果所必需的。这减少了显存读写量，也是 FlashAttention 提高效率的核心原因。